

Relatório de Testes Realizados em Perceptron com Saída Esparsa

Disciplina: Introdução à Neurociência Computacional

Profº: Raphael Y. Camargo / Marcelo B. Reis

Aluno: Wedeueis B. Silva R.A.: 11004813

Objetivo

Testar a capacidade de aprendizado e generalização de um perceptron com 20 neurônios de saída e codificação esparsa.

Metodologia

Na primeira parte foi utilizado um algoritmo modificado de aprendizado de um perceptron capaz de aprender a reconhecer, de forma simplificada (como visto em sala), 26 caracteres codificados em uma matriz de 12x13 cada. O algoritmo foi implementado em Octave com a codificação na saída variando entre 0.1 , 0.2 e 0.3 de esparsidade, para testar o impacto do aumento da esparsidade no aprendizado. Na segunda parte foi implementado um algoritmo que simula a desconexão de alguns neurônios da rede mostrando como o aprendizado é afetado em dois casos: quando a remoção é realizada antes e depois do aprendizado.

Resultados e Discussão

Parte 1 – Teste de aprendizado com diferentes esparsidades.

Gráficos gerados no Octave mostrando o aprendizado do perceptron através da queda na magnitude do erro global da rede:

Esparsidade de 0.1:




Figura 1 – Aprendizado com esparsidade de 0.1 na codificação de saída.

Esparsidade de 0.2:

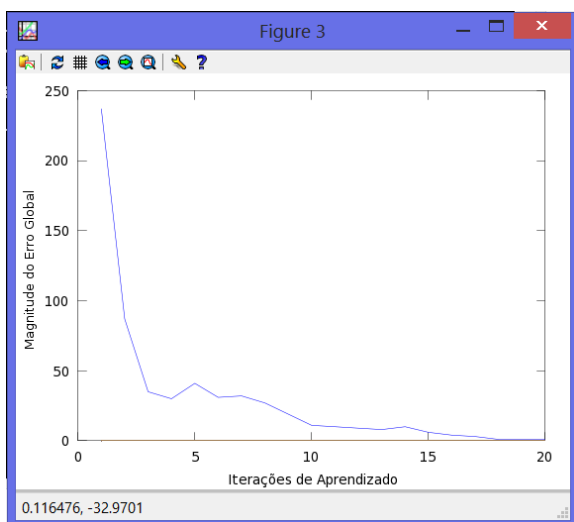


Figura 2 - Aprendizado com esparsidade de 0.2 na codificação de saída.

Esparsidade de 0.3:




Figura 3 - Aprendizado com esparsidade de 0.3 na codificação de saída.

Comparação da minimização do erro para as diferentes esparsidades:




Figura 4 - Comparação de aprendizado para Redes com diferentes esparsidades na codificação de saída.

Podemos verificar no gráfico que para os casos de esparsidade 0.1 e 0.2 o aprendizado foi praticamente equivalente, já com a esparsidade de 0.3 a rede encontrou maior dificuldade permanecendo com um erro relativamente alto após as 20 iterações de treinamento, provavelmente devido a similaridade dos padrões (overlap).

Parte 2 – Teste de tolerância à falhas.

2.1 - Remoção aleatória de conexões depois do aprendizado em diferentes esparsidades:

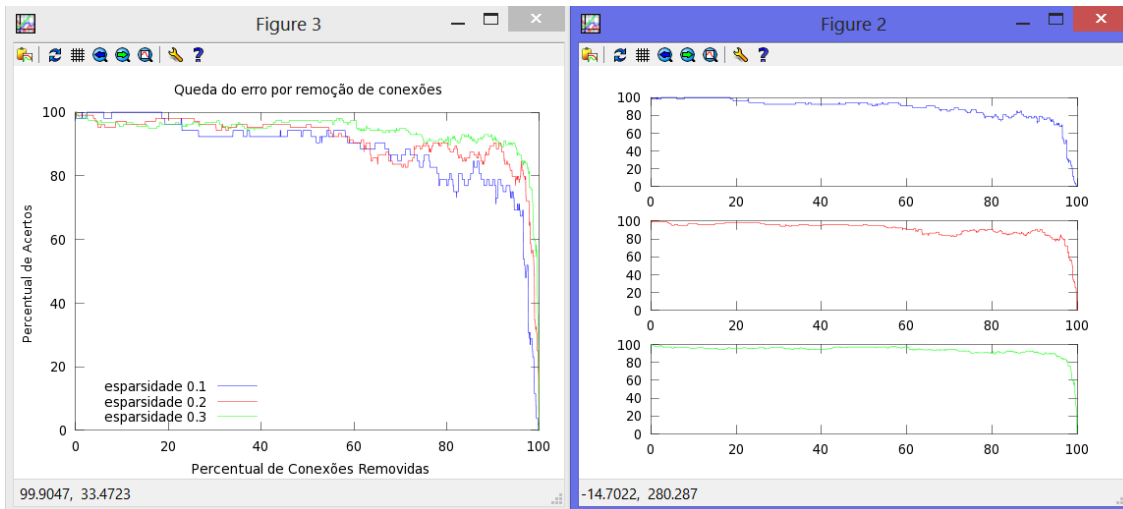


Figura 5 – Porcentagem de acertos da rede após remoção de conexões aleatoriamente.

Podemos verificar que o aumento na esparsidade leva a uma maior tolerância a falhas quando a remoção de conexões é realizada após o aprendizado, embora a quantidade de acertos nos três casos se mantenha maior que 80% até a remoção quase completa das conexões, um resultado relativamente alto demonstrando a robustez da rede.

2.2 - Remoção aleatória de conexões antes do aprendizado em diferentes esparsidades:

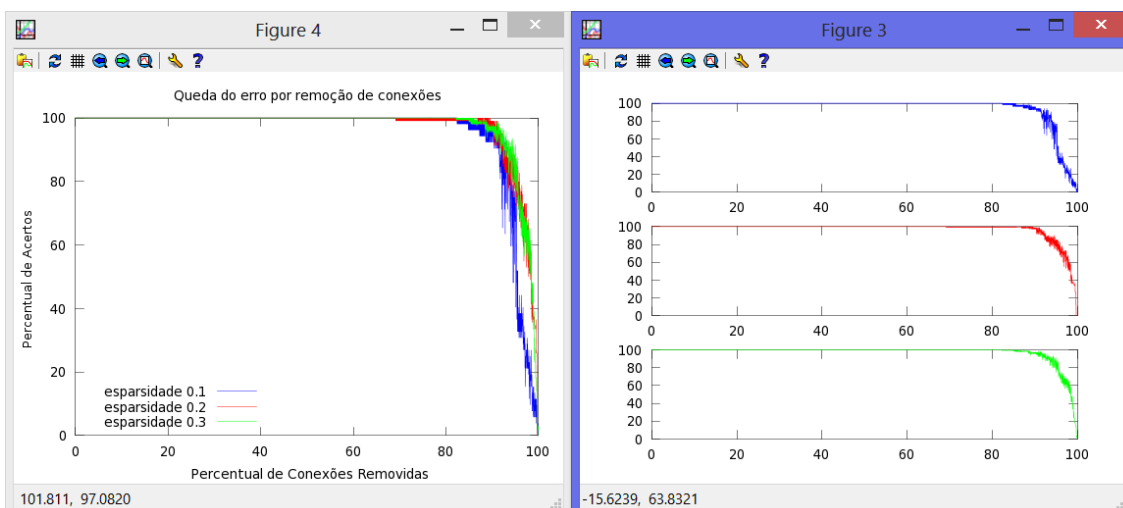


Figura 6 – Porcentagem de acertos da rede após remoção de conexões aleatoriamente.

Quando a remoção de conexões é realizada antes do treinamento da rede sua capacidade é inalterada até removermos quase completamente os pesos (mais que 80%) mostrando novamente seu alto grau de tolerância a falhas com um certo aumento em esparsidades maiores.

Conclusão

Os testes realizados demonstram o alto grau de tolerância de uma rede de neurônios com saída esparsa, apresentando seu melhor desempenho quando a remoção de conexões ocorre antes do aprendizado e com os maiores índices de esparsidade.